

《神经网络与深度学习课程》

第 2 次作业

发布日期：2026. 04. 22

提交截止时间：2026. 05. 07 24:00:00

作业要求：

1. 作业格式为：

（1）一个 PDF，里面按题目次序，包含回答、证明、计算过程、实验结果记录和分析等内容。

（2）一个代码文件夹，里面为实验代码。

以上的 PDF 和代码文件夹，打包压缩，发送到邮箱：

weilong@fudan.edu.cn，并抄送：25112030004@m.fudan.edu.cn。邮箱标题格式为“姓名-学号-第 x 次作业”，例如“张三-202500000000-第 2 次作业”。**该邮件格式规范要严格遵守。**

2. 作业须由每个人独立完成。

3. 作业中须有一个章节“AI 的使用方式”，在此章节中，**诚实地**声明 AI 的使用方式。如果未使用 AI，则在该章节里填“无”。

4. 迟交惩罚：24 小时内扣 1 分；48 小时内扣 2 分；超过 48 小时扣 5 分。

5. 备注：作业中所称“教材”指《神经网络与深度学习》，神经网络的记号与教材中保持一致。

1. 序列到序列预测模型（3分）

请训练 Seq2Seq（异步的序列到序列模式，见教材第 6.3.3 节）RNN 模型，该模型能够对一个输入的乱序且**不重复**的整数序列进行由大到小排序。例如，输入序列为[5, 2, 3, 7, 1]，则输出应为[7, 5, 3, 2, 1]。评估指标为测试集上的平均排序正确率：对于一条测试样本，只有当输出序列中所有位置排序完全正确时，该样本才算预测正确，否则算错误。请自己生成训练集和测试集，每个样本的序列长度为 5 到 8 之间，其中每个分量的取值范围 0 到 15 之间的整数，以上范围均包含两端数值。代码用 PyTorch 框架实现，请自己编写 Encoder 和 Decoder 模块的代码。

（1）分别实现两种 RNN 网络模型：

（a）教材第 6.3.3 节中的基础模式，即公式（6.25）、（6.26）和（6.27）；

（b）循环单元采用教材 6.6.1 节中的 LSTM，即公式（6.51）到公式（6.56）。

对比二者的测试效果，并观察训练过程，分析（b）相比（a）是否缓解了长程依赖问题。（1分）

（2）评估当测试样本的数值范围或者序列长度超出训练集时，（a）和（b）这两个网络模型的平均排序正确率是否会下降。（1分）

（3）借鉴教材中第 6.4 节中 RNN 的梯度推导方式，推导教材第 6.6.1 节中 LSTM 网络中参数的梯度，并分析其避免梯度消失的效果。（1分）

2. 图卷积网络（3分）

对于采用线性激活函数的图卷积网络（GCN），第 $k+1$ 层特征 $H^{(k+1)}$ 与 k 层特征 $H^{(k)}$ 的关系为 $H^{(k+1)} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(k)} W$ ，其中 $\tilde{A} = A + I$ 为自环邻接矩阵，若节点 i 和节点 j 相邻，则 $A_{ij} = 1$ ，否则 $A_{ij} = 0$ ； $\tilde{D}$ 为对角矩阵， $\tilde{D}_{ii} = \sum_j A_{ij}$ ； W 为可学习权重。令 $S = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ ，那么当图为无向连通图时，已经证明 S 的最大特征值为 1，其他特征值绝对值都小于 1。

（1）证明：对于无向连通图，当网络层数 K 趋于无穷大时，图卷积网络的所有节点的特征表示会逐渐收敛为共线向量，即方向相同，仅长度不同。该现象称为“过平滑”（Over-smoothing）现象。（1分）

（2）基于 PyTorch 库，设计一个数值实验，在合成数据上验证该结论。（1分）

（3）请提出可以缓解“过平滑”现象的方法，可参考相关文献，并在第（2）步中设计的合成数据上，通过实验验证提出的方法在缓解“过平滑”方面的效果。（1分）

3. 数据预处理与逐层规范化（1 分）

基于 Python 的 Pytorch 库，实现一个 3 层 MLP 模型。模型输入形状为 $\text{batch_size} \times \text{input_feature_size}$ ，输出形状为 $\text{batch_size} \times 1$ ，2 个隐藏层的形状都为 $\text{batch_size} \times \text{hidden_feature_size}$ ，激活函数都为 ReLU。要求如下：

- （1）对每个 mini-batch 的原始输入数据（即第 0 层的输出（活性值） $\mathbf{a}_0$ ）做 Z-值归一化（教材第 7.4 节），即将每一维特征都调整为均值为 0，方差为 1；
- （2）对第 1 层的净输入 $\mathbf{z}_1$ 做批量归一化，缩放参数 γ 和平移参数 β 是可学习的；
- （3）对第 2 层的净输入 $\mathbf{z}_2$ 做层归一化，缩放参数 γ 和平移参数 β 是可学习的；
- （4）实现过程中，可以使用 PyTorch 中的线性模型层，但不允许直接调用 PyTorch 库中的批量归一化和层归一化作为 MLP 的一层。

4. 网络优化器（3 分）

2 维双曲损失函数 $L(\theta_1, \theta_2) = \theta_1^2 - \theta_2^2$ 具有马鞍面形状的损失景观， $(0,0)$ 是其一个鞍点。完成以下数值实验：在相同的学习率参数 α 的条件下，从一个随机初始值 $(\theta_1^{(0)}, \theta_2^{(0)})$ 开始，分别用 SGD、RMSprop、AdaDelta、Adam 这 4 种优化器，对损失函数进行迭代最小化优化。 α 的定义与教材中 7.2.3 节、7.2.4.3 节（公式 7.29）中保持一致。

- （1）可视化各自优化过程，即将迭代序列 $\{\theta_1^{(k)}, \theta_2^{(k)}, k = 0, 1, 2, \dots\}$ 及其先后顺序在损失景观图上标注出来。（2 分）
- （2）优化过程中，各优化器逃离鞍点的速度如何？并分析原因。（1 分）